

RAPPORT DE PROJET – M1 MASS POP

PROJET TER
« AUDIENCE DES PUBLICATIONS
REGIONALES DE L'INSEE »

Projet réalisé par

Jamal ACHALHI

Farid ALI

ZOGLAMI Hakim

Projet encadré par

Pascale ROUAUD

TABLE DES MATIERES

I-INTRODUCTION.....	3
II-PRESENTATION	4
1- INSEE ET CONTEXTE	4
2- OBJECTIFS ET CONTRAINTES	5
III-PRESENTATIONS DES DONNEES ET METHODOLOGIE.....	6
1- LA BASE DE DONNEES	6
2- METHODOLOGIE	7
IV-RESULTATS	8
V- CONCLUSIONS.....	244
ANNEXES	25

I-INTRODUCTION

Dans le cadre de notre première année de Master 1, il nous est proposé un projet de 4 mois nous permettant de mettre en pratique nos connaissances et nos compétences au travers d'un projet, ayant pour finalité l'étude de données dans un cas concret et des données réels collectés par L'Institut national de la statistique et des études économiques (INSEE). Ayant une passion commune pour l'analyse de données, notre groupe composé de ACHALHI Jamal, ALI Farid, et ZOGHLAMI Hakim, a saisi l'opportunité d'exploiter cet intérêt commun pour soumettre un compte rendu de cette analyse.

L'objectif de cette analyse, est d'évaluer la position de la région Provence-Alpes-Côte d'Azur par rapport aux autres régions en termes de consultation de ses productions, d'identifier les facteurs déterminants qui influencent la visibilité d'une publication par rapport à une autre, de déterminer s'il existe une région où les publications sont particulièrement consultées, et enfin de voir s'il y aurait une potentiel corrélation entre les publications régionales et nationales. Dans ce cas, l'attention se portera sur cette région afin de comprendre les raisons de cette forte visibilité, dans le but d'améliorer la diffusion des données statistiques de la région Provence-Alpes-Côte d'Azur de manière similaire.

Dans le cadre de notre analyse, nous commencerons par une présentation des données pour offrir un aperçu du jeu de données en question, ce qui nous permettra de comprendre les enjeux du sujet. Ensuite, nous exposerons la méthodologie que nous utiliserons pour justifier les méthodes statistiques employées afin de répondre à notre question centrale.

II-PRESENTATION

1- INSEE ET CONTEXTE

Depuis sa création en 1946, l'Institut National de la Statistique et des Études Économiques, plus connu sous le nom d'Insee, est devenu un acteur central de la scène statistique française. Cet organisme public est placé sous la double tutelle du ministère de l'Économie, des Finances et de la Relance, ainsi que du Ministère chargé de la Statistique. Son rôle est crucial dans la collecte, l'analyse et la diffusion des données statistiques officielles en France. Cette collecte se fait par le biais d'enquêtes, de recensements et d'autres méthodes de collecte, permettant ainsi d'obtenir une image précise et exhaustive de la société et de l'économie françaises.

Elle s'engage à rendre ses données accessibles au public. À travers son site web, des publications officielles et des bases de données en ligne, l'Insee met à disposition ses statistiques pour une utilisation maximale. De plus, il fournit des services personnalisés et des outils d'analyse pour répondre aux besoins spécifiques des utilisateurs.

L'Insee, est donc chargé d'analyser et diffuser des données sur l'économie et la société françaises. La direction régionale de l'Insee en Provence-Alpes-Côte d'Azur (Paca) mène des études spécifiques sur cette région et les met à disposition du public, notamment via son site internet et les médias. Pour répondre à l'objectif du plan stratégique Insee 2025, qui vise à rendre les données accessibles à un large public, la direction régionale souhaite évaluer la visibilité et l'appropriation de ses publications.

Dans ce cadre, l'Insee a développé un logiciel interne appelé Statcraft pour suivre la fréquentation de son site internet, permettant ainsi d'analyser l'audience de ses publications. L'objectif principal est d'analyser le nombre de consultations et de téléchargements des publications coordonnées régionales de l'Insee parues en 2021 et 2022, en identifiant les facteurs explicatifs de ces chiffres.

Notre analyse consistera à comparer la région Provence-Alpes-Côte d'Azur avec les autres régions en termes de consultation de ses productions, de découvrir les facteurs qui influent sur la visibilité d'une publication par rapport à une autre, et d'identifier s'il existe une région où les publications sont particulièrement consultées. Dans ce contexte, une attention particulière sera portée à la région Provence-Alpes-Côte d'Azur afin de comprendre les raisons de sa forte visibilité, dans le but d'améliorer la diffusion des données statistiques de manière similaire.

2- OBJECTIFS ET CONTRAINTES

Dans le cadre de notre projet, nous avons restreint notre analyse aux publications relevant du type d'opération coordonnée de l'Insee pour les années 2021 et 2022. Une opération coordonnée se réfère à une initiative de l'Insee visant à mener des études sur une thématique commune simultanément dans toutes les régions de France. Ici, nous avons des publications qui se distinguent par le fait qu'elles sont diffusées simultanément dans toutes les régions et portent sur une thématique commune. Cette spécificité nous permet d'analyser des éléments comparables à travers toutes les régions, ce qui aurait été moins réalisable avec d'autres types d'opérations. Ainsi, en nous concentrant sur ces publications coordonnées, nous pourrions étudier de manière approfondie la réception et l'impact des données statistiques diffusées par l'Insee sur des sujets spécifiques au niveau régional.

Outre le fait que les publications sont issues d'un type d'opération défini selon plusieurs facteurs, elles appartiennent toutes à l'une des (collections régional ou national) que l'Insee propose. Nous nous sommes restreints à la collection régionale, à savoir la collection Insee Analyses et Insee Flash, qui ont pour spécificité de fournir respectivement des analyses détaillées et approfondies sur des sujets spécifiques et des données rapides sur des événements économiques ou sociaux significatifs.

III-PRESENTATIONS DES DONNEES ET METHODOLOGIE

1- LA BASE DE DONNEES

Nous disposons de deux bases de données provenant de l'Institut national de la statistique et des études économiques (INSEE). La première base de données constitue un catalogue regroupant toutes les informations relatives aux publications de l'INSEE. Cette base de données comprend plusieurs caractéristiques telles que la date de diffusion de chaque publication, la région où elle a été diffusée, la collection à laquelle elle appartient, le type de publication (opération coordonnées, Insee conjoncture), ainsi que d'autres détails spécifiques à chaque publication, comme son titre, son auteur, et éventuellement des mots-clés ou des catégories associées.

Cette première base de données est constituée de 497 lignes, et chaque ligne de cette base de données représente une publication spécifique publiée par l'INSEE. Cette base de données nous offre donc une vue globale de toutes les publications disponibles, ainsi que de leurs caractéristiques distinctes. Cela nous permettra d'analyser les tendances, les thèmes récurrents, les régions où les publications sont diffusées le plus souvent, et d'autres aspects qui peuvent être utiles pour comprendre la dynamique des vues des publications de l'INSEE au sein d'une région.

La seconde base de données est constituée de 2172191 lignes, et contient des informations plus spécifiques sur chaque visionnage de ces publications. Elle nous donne des détails sur les consultations des publications, y compris des informations telles que la date et l'heure de chaque consultation, ainsi que le type d'appareil utilisé pour consulter la publication (par exemple, ordinateur, tablette, smartphone). Ces données nous permettent de mieux comprendre les schémas de consultation des publications, les périodes de consultation les plus actives, les préférences en matière d'appareils, et d'autres informations pertinentes qui peuvent être utiles pour évaluer l'impact et la portée des publications l'INSEE.

Dans le cadre de cette analyse, nous allons étudier le nombre de consultation qui ont lieu dans les 30 jours suivant chaque date de diffusion d'une publication, car c'est pendant cette période que le nombre de vues est le plus concentré.

2- METHODOLOGIE

Pour cette étude, nous avons principalement utilisé le logiciel R pour toutes nos analyses statistiques. Pour représenter graphiquement nos données, nous avons opté pour des boxplot afin de visualiser la répartition des observations dans les collections que nous étudions. De plus, nous avons créé un tableau des dix publications les plus et les moins consultées, ainsi que des modèles de régression linéaire pour analyser les relations entre les variables explicatives et expliquées.

Nous avons également effectué des calculs de corrélation pour évaluer les liens potentiels entre les publications nationales et les opérations coordonnées. Nous nous sommes tout d'abord concentrés sur des tris à plat pour observer des tendances, concernant l'influence que pouvait avoir telle variable sur le nombre de vue d'une publication. Nous allons donc nous intéresser à la variable collection pour ainsi établir si la nature d'une publication, les thèmes abordés ont un rôle importantsur le nombre de vues que pourrait avoir un article.

Pour approfondir nos analyses on s'est aussi concentré sur la variable type qui nous indique l'opération coordonnée concernée par la publication, comme pour la variable précédente, cela nous permettra de comprendre le déterminisme que pourrait induire le sujet d'une étude, chaque opération coordonnée traite d'un sujet similaire; ensuite on se dirigera sur l'aspect géographique, les régions françaises sont riches sur les points de la diversité démographique, économique et culturelle, on pourrait donc s'attendre à ce que cette variable puisse expliquer en partie le nombre de vuesd'une publication.

Nous allons ensuite travailler sur la variable mois/jour de diffusion, dans une société très périodique et calibrée minutieusement, on peuts'attendre à ce que la période de la semaine ou de l'année puisse induire une variation de la consultation d'une publication.


En ce qui concerne la cartographie, nous avons utilisé le site statistique locale développé par l'Insee, qui permet de générer des représentations cartographiques en fonction des données fournies permettant d'observer plus facilement les tendances, la réalisation d'une régression linéaire simple et multiple pourrait nous aider donc à conclure quant à nos recherches.

IV-RESULTATS

Pour obtenir nos résultats, nous avons regroupé les données par région et par titre de publication. Ensuite, pour chaque région, nous avons additionné toutes les vues des publications ayant le même titre. Cette approche nous permet de mieux comprendre comment les publications de l'Insee sont consultées dans chaque région spécifique. Tout au long de notre études et de nos analyses, nous avons travaillé exclusivement avec une table f comprenant uniquement les publications d'Insee Flash et d'Insee Analyses. Cette table finale regroupe un total de 137 publications.

FIGURES 1 :


Répartition des publications selon la collection



On constate que "Insee Flash" compte largement plus de publication que la collection "Insee Analyses". Cette différence met en évidence la prédominance des publications rapides et événementielles de "Insee Flash" par rapport aux analyses détaillées de "Insee Analyses".

FIGURE 2 :

NOMBRE DE VUE MEDIAN PAR REGION



Dans notre carte du nombre de vues médian selon la région, trois régions se démarquent avec une moyenne de vues dépassant les 1000 : Auvergne Rhône-Alpes, Normandie et Île-de-France. En revanche, trois autres régions affichent les médianes les plus basses qui sont par exemple : le Val de Loire, la Guadeloupe et la Martinique. On constate donc que les régions telles que Rhône-Alpes, Normandie et Île-de-France semblent susciter un plus grand intérêt, avec des médianes de vues dépassant les 1000. Cela pourrait refléter une concentration plus importante d'activités économiques, sociales ou médiatiques dans ces régions, ce qui attire potentiellement davantage d'attention sur les données statistiques. En revanche, les régions comme le Val de Loire, la Guadeloupe et la Martinique affichent des médianes de vues plus basses, suggérant un niveau d'intérêt relativement plus faible pour les données de l'Insee. Cela pourrait être dû à des facteurs tels que la taille de la population, les spécificités économiques ou culturelles de la région, ou encore le niveau de disponibilité et de sensibilisation aux données statistiques.

FIGURE 3 :

Nombre de publications étudiées par région - Source :




Grâce à l'analyse de la carte du nombre de vues médian par région, nous avons constaté que la région avec le plus grand nombre de publications est celle du Centre-Val de Loire.

Cependant, précédemment, nous avons remarqué que cette même région présentait le moins de vues médianes par rapport aux autres régions. Cela suscite donc un intérêt particulier pour explorer ce phénomène.

Par ailleurs, nous remarquons que les autres régions présentent un nombre de publications plutôt homogène, tandis que la Guyane se distingue avec le moins de publications. Notre prochaine étape consistera à examiner les types de publications dans ces régions afin de mieux comprendre ces observations contradictoires.

FIGURE 4 :



Dans le graphique ci-dessus, on remarque une petite différence entre les deux types de publications. Pour les publications d’Insee Flash, le nombre médian de vues est de 795,5, alors que pour celles d’Insee Analyses, il est de 789. Même si Insee Flash a plus de publications en général, les données suggèrent que les gens s’intéressent un peu plus aux publications d’Insee Analyses en moyenne. Cela montre qu’il est important de considérer la qualité des publications en plus de leur quantité lorsqu’on regarde les données statistiques.

Dans le cas d’Insee Flash, la médiane est légèrement inférieure à la moyenne, mais les valeurs extrêmes plus élevées font que la moyenne est plus élevée. Cela pourrait signifier qu’il y a quelques publications très populaires qui ont un impact important sur la moyenne.

Pour Insee Analyses, la médiane et la moyenne sont plus proches l’une de l’autre, ce qui suggère une distribution de données plus équilibrée. Cependant, la moyenne est toujours plus élevée que la médiane, indiquant également l’influence de quelques valeurs plus élevées.

On en conclut que ces résultats sous-entendent que la collection Insee Flash présente une plus grande variabilité dans le nombre de vues par rapport à la collection Insee Analyses, avec des valeurs médianes et moyennes légèrement plus élevées, ainsi qu’une dispersion des données plus importante.

Cette première figure nous montre bien que la collection Insee Flash est plus attractive (dû au nombre important de publication) que l’Insee Analyses. Grâce à la base de données que nous possédons, nous allons voir quelle sont les raisons de cette différence de vu qui peut être du à :


- Un contenu plus attractif ?
- Format plus concis ?
- Diffusions plus fréquentes ?
- Promotion plus efficace ?
- Audience ciblé différente ?

Dans notre intérêt en tant que chercheurs, nous aimerions savoir quel mois est le plus propice pour que notre publication touche le plus grand nombre de personnes possible. Nous avons donc fait le graphique ci-dessous :

FIGURE 5:

Les

Nombre de vue médian par mois de diffusion




données montrent une tendance saisonnière claire. A noter ici qu'il manque les mois d'Avril, Mai, Juillet, Aout, Septembre et Octobre car il y a eu zéro publication durant ses mois. On observe une hausse des vues vers la fin de l'année, en particulier en décembre, probablement liée à la période des fêtes. De même, en janvier, juste après les fêtes, il y a un pic d'attention. Ces variations saisonnières soulignent l'importance de prendre en compte le calendrier lors de la planification de la diffusion de nos publications, afin de maximiser l'impact et l'intérêt du public.

Maintenant, nous allons nous intéresser à l'année de diffusion pour les publications.

FIGURE 6 :


Nombre de vue médian par année de diffusion



En 2021 il y a eu 31 publications dont 22, de ces publications faisaient partie de la collection INSEE Flash et 19 d'INSEE Analyse, tandis qu'en 2022, ce nombre a augmenté significativement pour atteindre 106 publications donc 90 faisaient partie de la collection INSEE Analyse et 16 d'INSEE Flash. Les données nous indiquent une baisse du nombre de vues médian entre 2021 et 2022. Cela montre une diminution de l'attention ou de l'intérêt pour les publications au fil du temps. Il est important de prendre en compte les facteurs externes qui pourraient influencer cette tendance, tels que les événements économiques ou sociaux, les changements dans les pratiques de publication ou la concurrence accrue pour l'attention du public.


FIGURE 7:

Nombre de vue médian annuel par collection



En analysant en profondeur le nombre de vues médian par collection pour chaque année, on constate une évolution contrastée qui suggère des tendances différentes dans la consultation des publications des deux collections au fil des années. En 2021, se sont les Insee Flash (22 publications sur les 31) les plus convoitées tandis qu'en 2022, ça serait les Insee analyses (90 publications sur les 106). La tendance c'est inversée. On pourrait donc se demander qu'elles sont les facteurs qui ont influencé ces changements pour mieux comprendre les dynamiques d'intérêt du public. Dans notre cas à nous, nous allons nous focaliser sur les types d'opération coordonnées.

FIGURE 8:



Nous avons d'abord examiné le nombre de vues médian d'une publication en fonction de sa thématique. Comme illustré ci-dessus, le nombre de vues médian le plus élevé a été observé pour les publications issues des opérations coordonnées sur les populations légales en 2021, avec un total de 2028 vues médian. Cette thématique présente probablement un nombre de vues médian plus élevé en raison de leur pertinence, de leur demande institutionnelle, de leur fréquence de mise à jour, de leur large audience potentielle et de leur accessibilité. Or, en 2022 la tendance change car l'opération coordonnée précédemment passe deuxième, laissant sa place à l'opération coordonnée sur les Ruraux et provinciaux avec un total de vue médian de 1393.

Enfin, nous allons maintenant explorer s'il existe un lien entre le nombre de vues et les régions, ainsi qu'entre le nombre de vues et le type de publication, car il est possible qu'il y ait une audience plus importante pour certains sujets spécifiques par rapport à d'autres.

Avant de commencer nos tests d'association des variables, nous avons d'abord regroupé les données de nombre de vue en six intervalles, allant de 244 à 2850, afin de pouvoir appliquer le test correctement.

Voici comment on a procédé :

Minimum des données de vue : 244

Maximum des données de vue : 2850

Nombre d'intervalles choisi : 6

Largeur de l'intervalle : $(2850 - 244) / 6 \approx 441$

Intervalles : (244 – 684) (685 – 1125) (1126 – 1566) (1567 – 2007) (2008 – 2448) (2449 – 2850)

Nous avons obtenu les résultats suivants :

FIGURE 9 : TEST D'ASSOCIATION DES VARIABLES

Pearson's Chi-squared test

```
data: nvelle_table$class_vues and nvelle_table$moisdiffusion  
X-squared = 121.34, df = 15, p-value < 2.2e-16
```

Pearson's Chi-squared test

```
data: nvelle_table$class_vues and nvelle_table$anneediffusion  
X-squared = 15.151, df = 3, p-value = 0.001692
```

Pearson's Chi-squared test

```
data: nvelle_table$class_vues and nvelle_table$collection.x  
X-squared = 5.1867, df = 3, p-value = 0.1586
```

Pearson's Chi-squared test

```
data: nvelle_table$class_vues and nvelle_table$type.x  
X-squared = 153.68, df = 24, p-value < 2.2e-16
```

Pearson's Chi-squared test

```
data: nvelle_table$class_vues and nvelle_table$region.x  
X-squared = 46.717, df = 48, p-value = 0.5255
```


À la suite des résultats, nous constatons que les variables "type", "mois de diffusion" et "année de diffusion" ont une p-valeur inférieure à 0,05, ce qui suggère une relation significative avec le nombre de vues. En revanche, les variables "collection" et "région" ont une p-valeur supérieure à 0,05, indiquant qu'elles n'ont pas un impact significatif sur le nombre de vues générées par les publications. Donc, le type le mois et années de diffusion non un impact sur le nombre de vue générer sur les publications.

On va pouvoir maintenant passer aux régressions linéaires pour regarder plus en détail quel facteur exact joue un rôle essentiel sur le nombre de vu des publications.

FIGURE 10: REGRESSION LINEAIRE DU NOMBRE DE VUE PAR RAPPORT AUX REGIONS

```
Call:
lm(formula = nvelle_table$vues_hors_robots ~ nvelle_table$region.x)

Residuals:
    Min       1Q   Median       3Q      Max
-729.8  -285.4  -152.2   145.3  1618.9

Coefficients:
(Intercept)                1184.75      186.97      6.337 4.27e-09 ***
nvelle_table$region.xBourgogne-Franche-Comté    -204.64      256.96     -0.796  0.4274
nvelle_table$region.xBretagne                   -228.32      273.69     -0.834  0.4058
nvelle_table$region.xCentre-val de Loire        -451.75      241.37     -1.872  0.0637 .
nvelle_table$region.xCorse                      -251.62      264.41     -0.952  0.3432
nvelle_table$region.xGrand Est                  -180.31      256.96     -0.702  0.4842
nvelle_table$region.xGuadeloupe                -476.86      256.96     -1.856  0.0659 .
nvelle_table$region.xGuyane                    -520.08      285.60     -1.821  0.0711 .
nvelle_table$region.xHauts-de-France            -170.37      264.41     -0.644  0.5206
nvelle_table$region.xIle-de-France              -29.62      264.41     -0.112  0.9110
nvelle_table$region.xMartinique                 -551.89      273.69     -2.016  0.0460 *
nvelle_table$region.xNormandie                  231.25      264.41      0.875  0.3835
nvelle_table$region.xNouvelle-Aquitaine         -150.00      264.41     -0.567  0.5716
nvelle_table$region.xoccitanie                   46.39      273.69      0.170  0.8657
nvelle_table$region.xPays de la Loire           -70.89      273.69     -0.259  0.7961
nvelle_table$region.xProvence-Alpes-Côte d'Azur -106.75      264.41     -0.404  0.6871
nvelle_table$region.xRéunion                    -234.50      264.41     -0.887  0.3769
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 528.8 on 120 degrees of freedom
Multiple R-squared:  0.1441,    Adjusted R-squared:  0.02998
F-statistic: 1.263 on 16 and 120 DF,  p-value: 0.2324
```

Après avoir effectué une régression linéaire entre le nombre de vues des publications de l'INSEE et les régions de France, nous avons obtenu des résultats intéressants. Globalement, le modèle semble avoir une faible capacité à expliquer la variation du nombre de vues, avec un R^2 ajusté de 0.030, indiquant que seulement environ 3% de la variation dans le nombre de vues peut être expliquée par les régions.

En examinant les coefficients associés à chaque région, nous constatons que la région du Centre-Val de Loire présente le coefficient le plus négatif (-451.75), suggérant une diminution significative du nombre de vues comparativement à la région de référence (Auvergne Rhône Alpes). Cependant, cette différence n'est pas statistiquement significative, avec une p-valeur de 0.0637.

De même, la Martinique présente un coefficient significativement négatif (-551.89), indiquant également une baisse marquée du nombre de vues. Cependant, cette différence est statistiquement significative, avec une p-valeur de 0.0460, ce qui suggère une association significative entre la région de la Martinique et le nombre de vues.

Cependant, il est important de noter que la plupart des autres régions ne présentent pas de coefficients significativement différents de zéro, ce qui suggère que le nombre de vues n'est pas fortement influencé par la région dans laquelle une publication est diffusée.

En conclusion, bien que la région du Centre-Val de Loire et la Martinique semblent montrer des tendances de diminution significative du nombre de vues par rapport à la région de référence, la faible valeur du R^2 ajusté et les valeurs p-valeurs élevées suggèrent que d'autres facteurs non inclus dans le modèle peuvent jouer un rôle important dans la détermination du nombre de vues des publications de l'INSEE.

FIGURE 11 : REGRESSION LINEAIRE DU NOMBRE DE VUE PAR RAPPORT AUX TYPES DE PUBLICATIONS

```
call:
lm(formula = nvelle_table$votes_hors_robots ~ nvelle_table$type.x)

Residuals:
    Min       1Q   Median       3Q      Max
-795.41 -138.57  -27.41  120.86 1008.94

Coefficients:
                                Estimate Std. Error t value Pr(>|t|)
(Intercept)                   566.67      71.14    7.966 7.77e-13 ***
nvelle_table$type.xpopulation légale 2021    -22.10     102.39   -0.216 0.829486
nvelle_table$type.xcommunautés 2022         203.33     109.37    1.859 0.065305 .
nvelle_table$type.xfemme2022              237.61     109.37    2.172 0.031660 *
nvelle_table$type.xégalité homme femme 2022  223.40      99.02    2.256 0.025765 *
nvelle_table$type.xparticipation électorale 2022 384.89      96.32    3.996 0.000108 ***
nvelle_table$type.xpopulation légale 2022     1475.75      97.60   15.120 < 2e-16 ***
nvelle_table$type.xprojection 2022           240.47      92.26    2.607 0.010232 *
nvelle_table$type.xruraux et périurbains 2022  894.79     104.40    8.571 2.85e-14 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 275.5 on 128 degrees of freedom
Multiple R-squared:  0.7522,    Adjusted R-squared:  0.7367
F-statistic: 48.56 on 8 and 128 DF,  p-value: < 2.2e-16
```

Dans cette régression du nombre de vues par rapport au type de publication, nous avons obtenu des résultats significatifs et intéressants. Le modèle semble avoir une bonne capacité à expliquer la variation du nombre de vues, avec un R^2 ajusté de 0.737, ce qui indique que près de 74% de la variation du nombre de vues peut être expliquée par le type de publication.

En regardant de plus près les coefficients associés à chaque type de publication, nous constatons que plusieurs d'entre eux ont des coefficients significativement différents de zéro, ce qui suppose qu'il y a une association significative entre ces types de publication et le nombre de vues.

En particulier, les types de publication "participation électorale 2022", "population légale 2022" et "ruraux et périurbains 2022" présentent des coefficients positifs et significatifs, ce qui montre une augmentation du nombre de vues associée à ces types de publication. D'autre part, les types de publication "population légale 2021", "communautés 2022", "femme 2022" et "égalité homme femme 2022" ont des coefficients non significatifs, ce qui évoque qu'ils ne sont pas fortement associés au nombre de vues.

Cette analyse sous-entend donc qu'il existe une relation significative entre le type de publication et le nombre de vues, avec certains types de publication exerçant une influence plus importante sur le nombre de vues que d'autres. Cela souligne l'importance de prendre en compte le type de publication lors de l'analyse des facteurs influençant le nombre de vues des publications de l'INSEE.

Figure 12: Régression linéaire du nombre de vue par rapport aux collections

```
Call:
lm(formula = nvelle_table$vues_hors_robots ~ nvelle_table$collection.x)

Residuals:
    Min       1Q   Median       3Q      Max
-763.2  -362.2  -206.2   292.8  1842.8

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)      893.5       99.7    8.962 2.29e-15 ***
nvelle_table$collection.xInsee Flash    113.7       112.3    1.013    0.313
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 536.9 on 135 degrees of freedom
Multiple R-squared:  0.007538, Adjusted R-squared:  0.0001866
F-statistic: 1.025 on 1 and 135 DF, p-value: 0.3131
```

Dans ce modèle, nous constatons à première vue que les résultats ne semblent pas être significatifs. En effet le modèle ne semble pas avoir une bonne capacité à expliquer la variation du nombre de vues, avec un R^2 ajusté très faible de 0.0001866, ce qui indique que la variation du nombre de vues n'est pas bien expliquée par les collections.

Le coefficient associé à la collection "Insee Flash", n'est pas statistiquement significatif, avec une p-valeur de 0.3131. Il n'y a donc pas de différence significative dans le nombre de vues entre les publications de la collection "Insee Flash" et les autres collections.

Nous pouvons donc supposer qu'il n'y a pas de relation significative entre les collections et le nombre de vues des publications de l'INSEE. Il est possible que d'autres facteurs non inclus dans le modèle puissent mieux expliquer la variation du nombre de vues, et il pourrait être intéressant d'explorer ces facteurs dans des analyses futures.

FIGURE 13: REGRESSION LINEAIRE DU NOMBRE DE VUE PAR RAPPORT A L'ANNEE DE DIFFUSION

```
Call:
lm(formula = nvelle_table$vues_hors_robots ~ nvelle_table$anneediffusion)

Residuals:
    Min       1Q   Median       3Q      Max
-1121.97  -308.15   -94.15   383.85  1484.03

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    1001390.7    205137.3     4.882 2.92e-06 ***
nvelle_table$anneediffusion    -494.8       101.5    -4.877 2.99e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 496.9 on 135 degrees of freedom
Multiple R-squared:  0.1498,    Adjusted R-squared:  0.1435
F-statistic: 23.78 on 1 and 135 DF,  p-value: 2.986e-06
```

Dans cette régression du nombre de vues par rapport à l'année de diffusion, nous obtenons des résultats significatifs. Le modèle semble avoir une capacité raisonnable à expliquer la variation du nombre de vues, avec un R^2 ajusté de 0.1435, ce qui indique que près de 14% de la variation du nombre de vues peut être expliquée par l'année de diffusion.

Nous constatons que le coefficient associé à l'année de diffusion est statistiquement significatif, avec une p-valeur très faible de 2.99e-06. Cela laisse penser qu'il existe une association significative entre l'année de diffusion et le nombre de vues des publications de l'INSEE.

Le coefficient négatif associé à l'année de diffusion (-494.8) indique qu'il y a une tendance à une diminution du nombre de vues au fil des années. Cependant, il est important de noter que ce résultat peut être influencé aussi par d'autres facteurs non inclus dans le modèle.

En conclusion, cette analyse montre qu'il existe une relation significative entre l'année de diffusion et le nombre de vues des publications de l'INSEE, avec une tendance à la baisse du nombre de vues au fil des années. Cependant, d'autres facteurs peuvent également influencer le nombre de vues et devraient être pris en compte dans des analyses plus approfondies.

FIGURE 14 : REGRESSION LINEAIRE DU NOMBRE DE VUE PAR RAPPORT AU MOIS DE DIFFUSION

```
call:
lm(formula = nvelle_table$vues_hors_robots ~ nvelle_table$moisdiffusion)

Residuals:
    Min       1Q   Median       3Q      Max
-927.40 -156.46  -44.14   133.33 1368.60

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    1461.46    108.72   13.442 < 2e-16 ***
nvelle_table$moisdiffusionFévrier    -916.89    150.98   -6.073 1.27e-08 ***
nvelle_table$moisdiffusionMars       -674.33    137.13   -4.917 2.58e-06 ***
nvelle_table$moisdiffusionJuin       -894.79    148.54   -6.024 1.61e-08 ***
nvelle_table$moisdiffusionNovembre   -661.51    125.95   -5.252 5.92e-07 ***
nvelle_table$moisdiffusionDecembre    19.94    127.32    0.157  0.876

---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 392 on 131 degrees of freedom
Multiple R-squared:  0.4866,    Adjusted R-squared:  0.467
F-statistic: 24.83 on 5 and 131 DF,  p-value: < 2.2e-16
```

Dans cette régression du nombre de vues par rapport au mois de diffusion, nous obtenons des résultats significatifs. Le modèle semble avoir une bonne capacité à expliquer la variation du nombre de vues, avec un R^2 ajusté de 0.467, ce qui indique que près de 47% de la variation du nombre de vues peut être expliquée par le mois de diffusion.

Nous pouvons voir que la plupart des coefficients associés à chaque mois de diffusion sont statistiquement significatifs, avec des p-valeurs très faibles. Ça suppose qu'il existe une association significative entre le mois de diffusion et le nombre de vues des publications de l'INSEE.

En effet, les coefficients négatifs associés à Février, Mars, Juin et Novembre nous montrent qu'il y a une tendance à une diminution du nombre de vues pendant ces mois par rapport au mois de référence (Janvier). En revanche, le coefficient associé à Décembre est positif mais non significatif, ce qui suggère qu'il n'y a sûrement pas de différence significative dans le nombre de vues par rapport à Janvier.

Nous pouvons donc conclure qu'il existe une relation significative entre le mois de diffusion et le nombre de vues des publications de l'INSEE, avec des variations saisonnières importantes. Ces résultats pourraient être utiles pour planifier la diffusion de futures publications afin de maximiser leur visibilité.

FIGURE 15 : PROJECTION DU NOMBRE DE VUE HORS ROBOT DE LA REGION PACA EN 2025 EN FONCTION DE NOTRE JEUX DE DONNEE

```
# Filtrer les données pour inclure uniquement les observations de la région Provence-Alpes-Côte d'Azur
donnees_paca <- subset(nouvelle_table, region == "Provence-Alpes-Côte d'Azur")

# Prédire les valeurs de vues_hors_robots pour la région PACA
donnees_paca$vues_hors_robots_predites <- predict(modele, newdata = donnees_paca)

# Afficher les prédictions pour la région PACA
print(donnees_paca)
```

	type	vues_hors_robots	moisdiffusion	anneediffusion	vues_hors_robots_predites
Développement des entreprises	2021	406	2	2021	1204.4673
Population légales	2021	2114	12	2021	1498.9681
Ruraux et provinciaux		1442	1	2022	677.5027
Etude Homme femme	2022	997	3	2022	736.4029
Communauté	2022	700	6	2022	824.7532
Participation election	2022	806	11	2022	972.0036
Projection	2022	847	11	2022	972.0036
Population légales	2022	1312	12	2022	1001.4537

Après avoir observé l'influence significative du mois de diffusion et de l'année sur le nombre de vues, nous avons entrepris de prédire le nombre de vues hors robots pour nos articles en fonction de ces variables. Ces prédictions sont basées sur le modèle de régression linéaire ajusté, qui utilise les mois de diffusion, les années de diffusion et éventuellement pour estimer le nombre de vues hors robots pour chaque produit dans la région PACA.

Nous constatons que toutes ces publications font parties de la collections INSEE Flash. Par exemple, pour la publication 5056747, et dont le titre est "Emploi salarié – Croissance « externe » dans les grandes entreprises, « interne » dans les plus petites", la valeur prédite du nombre de vues hors robots est de 1204.4673.

De même, pour d'autres publications de la région PACA, comme celui avec l'identifiant 6011880 et le titre "Populations légales – Entre 2013 et 2019, la croissance démographique accélère légèrement", la valeur prédite du nombre de vues hors robots est de 1498.9681.

V- CONCLUSIONS

En conclusion, nos analyses révèlent l'importance d'une stratégie réfléchie pour maximiser la visibilité de nos publications de l'INSEE. Tout d'abord, nous avons constaté que les collections de l'INSEE ne semblent pas être des facteurs influençant significativement le nombre de vues.

Nous avons également observé que certaines régions, telles que la Martinique, exercent une influence plus marquée que d'autres, ce qui pourrait être attribuable à des facteurs tels que la taille de la population ou l'intérêt spécifique pour les données statistiques dans ces régions.


En ce qui concerne les années de publication, nous avons constaté que l'année en elle-même n'a pas un impact majeur sur le nombre de vues. Cependant, le sujet de la publication semble jouer un rôle important. Par exemple, la population légale en 2021 semble attirer davantage d'attention. Ainsi, il est crucial de choisir des sujets qui correspondent à l'actualité et aux préoccupations du moment.

De plus, le moment de la publication est également un facteur clé. Nos données montrent qu'il est préférable de publier en janvier ou en décembre pour atteindre un public plus large, suggérant que le contexte saisonnier ou festif peut influencer l'attention portée aux publications.

Concernant la région PACA, nous avons remarqué grâce à la carte du nombre de vues que parmi les 8 publications étudiées dans cette région, elles provenaient toutes de la collection Insee Flash. Cela suppose que dans notre région, la population a plus tendance à lire des articles moins lourds et plus facilement accessibles sur internet, contrairement à d'autres régions. De plus, en comparant le nombre de vues hors robot médian, nous avons constaté que nous étions à 922, ce qui était plutôt encourageant pour notre région, contrairement à d'autres régions comme la région Centre-Val de Loire, qui en comptait le moins malgré un nombre plus élevé de publications.

Enfin, nos prédictions pour l'année 2025 montrent globalement une légère hausse du nombre de vues hors robot, sauf pour quelques thématiques centrées sur les populations. Ces résultats soulignent l'importance de prendre en compte divers facteurs pour élaborer une stratégie de publication efficace et atteindre notre public cible.

ANNEXES



```
Call:
lm(formula = nvelle_table$vués_hors_robots ~ nvelle_table$type.x)
```


```
Residuals:
    Min       1Q   Median       3Q      Max
-795.41 -138.57  -27.41  120.86 1008.94
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)      566.67      71.14   7.966 7.77e-13 ***
nvelle_table$type.xpopulation légale 2021      -22.10      102.39  -0.216 0.829486 .
nvelle_table$type.xcommunautés 2022       203.33      109.37   1.859 0.065305 .
nvelle_table$type.xfemme2022       237.61      109.37   2.172 0.031660 *
nvelle_table$type.xégalité homme femme 2022    223.40       99.02   2.256 0.025765 *
nvelle_table$type.xparticipation électorale 2022  384.89       96.32   3.996 0.000108 ***
nvelle_table$type.xpopulation légale 2022    1475.75       97.60  15.120 < 2e-16 ***
nvelle_table$type.xprojection 2022       240.47       92.26   2.607 0.010232 *
nvelle_table$type.xruraux et pronviçaux 2022    894.79      104.40   8.571 2.85e-14 ***
---
```

```
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 275.5 on 128 degrees of freedom
Multiple R-squared:  0.7522,    Adjusted R-squared:  0.7367
F-statistic: 48.56 on 8 and 128 DF,  p-value: < 2.2e-16
```

Nombre de publications étudiées par région - Source :



Géographie au 01/01/2023 - © IGN - Insee 2023



Call:

```
lm(formula = nvelle_table$views_hors_robots ~ nvelle_table$region.x)
```

Residuals:

```
Min      1Q  Median      3Q      Max
-729.8 -285.4 -152.2  145.3 1618.9
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	1184.75	186.97	6.337	4.27e-09	***
nvelle_table\$region.xBourgogne-Franche-Comté	-204.64	256.96	-0.796	0.4274	
nvelle_table\$region.xBretagne	-228.32	273.69	-0.834	0.4058	
nvelle_table\$region.xCentre-val de Loire	-451.75	241.37	-1.872	0.0637	.
nvelle_table\$region.xCorse	-251.62	264.41	-0.952	0.3432	
nvelle_table\$region.xGrand Est	-180.31	256.96	-0.702	0.4842	
nvelle_table\$region.xGuadeloupe	-476.86	256.96	-1.856	0.0659	.
nvelle_table\$region.xGuyane	-520.08	285.60	-1.821	0.0711	.
nvelle_table\$region.xHauts-de-France	-170.37	264.41	-0.644	0.5206	
nvelle_table\$region.xIle-de-France	-29.62	264.41	-0.112	0.9110	
nvelle_table\$region.xMartinique	-551.89	273.69	-2.016	0.0460	*
nvelle_table\$region.xNormandie	231.25	264.41	0.875	0.3835	
nvelle_table\$region.xNouvelle-Aquitaine	-150.00	264.41	-0.567	0.5716	
nvelle_table\$region.xOccitanie	46.39	273.69	0.170	0.8657	
nvelle_table\$region.xPays de la Loire	-70.89	273.69	-0.259	0.7961	
nvelle_table\$region.xProvence-Alpes-Côte d'Azur	-106.75	264.41	-0.404	0.6871	
nvelle_table\$region.xRéunion	-234.50	264.41	-0.887	0.3769	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 528.8 on 120 degrees of freedom

Multiple R-squared: 0.1441, Adjusted R-squared: 0.02998

F-statistic: 1.263 on 16 and 120 DF, p-value: 0.2324


```

Call:
lm(formula = nvelle_table$vues_hors_robots ~ nvelle_table$collection.x)

Residuals:
    Min       1Q   Median       3Q      Max
-763.2  -362.2  -206.2   292.8  1842.8

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)      893.5      99.7    8.962 2.29e-15 ***
nvelle_table$collection.xInsee Flash    113.7     112.3    1.013    0.313
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 536.9 on 135 degrees of freedom
Multiple R-squared:  0.007538, Adjusted R-squared:  0.0001866
F-statistic: 1.025 on 1 and 135 DF, p-value: 0.3131

Call:
lm(formula = nvelle_table$vues_hors_robots ~ nvelle_table$anneediffusion)

Residuals:
    Min       1Q   Median       3Q      Max
-1121.97  -308.15   -94.15   383.85  1484.03

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1001390.7   205137.3    4.882 2.92e-06 ***
nvelle_table$anneediffusion    -494.8     101.5   -4.877 2.99e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 496.9 on 135 degrees of freedom
Multiple R-squared:  0.1498, Adjusted R-squared:  0.1435
F-statistic: 23.78 on 1 and 135 DF, p-value: 2.986e-06

Call:
lm(formula = nvelle_table$vues_hors_robots ~ nvelle_table$moisdiffusion)

Residuals:
    Min       1Q   Median       3Q      Max
-927.40 -156.46  -44.14   133.33  1368.60

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    1461.46    108.72   13.442 < 2e-16 ***
nvelle_table$moisdiffusionFévrier    -916.89    150.98   -6.073 1.27e-08 ***
nvelle_table$moisdiffusionMars       -674.33    137.13   -4.917 2.58e-06 ***
nvelle_table$moisdiffusionJuin       -894.79    148.54   -6.024 1.61e-08 ***
nvelle_table$moisdiffusionNovembre  -661.51    125.95   -5.252 5.92e-07 ***
nvelle_table$moisdiffusionDecembre    19.94    127.32    0.157    0.876
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 392 on 131 degrees of freedom
Multiple R-squared:  0.4866, Adjusted R-squared:  0.467
F-statistic: 24.83 on 5 and 131 DF, p-value: < 2.2e-16

```

```

# Filtrer les données pour inclure uniquement les observations de la région Provence-Alpes-Côte d'Azur
donnees_paca <- subset(nouvelle_table, region == "Provence-Alpes-Côte d'Azur")

# Prédire les valeurs de vues_hors_robots pour la région PACA
donnees_paca$vues_hors_robots_predites <- predict(modele, newdata = donnees_paca)

# Afficher les prédictions pour la région PACA
print(donnees_paca)

```

	type	vues_hors_robots	moisdiffusion	anneediffusion	vues_hors_robots_predites
Développement des entreprises	2021	406	2	2021	1204.4673
Population légales	2021	2114	12	2021	1498.9681
Ruraux et provinciaux		1442	1	2022	677.5027
Etude Homme femme	2022	997	3	2022	736.4029
Communauté	2022	700	6	2022	824.7532
Participation election	2022	806	11	2022	972.0036
Projection	2022	847	11	2022	972.0036
Population légales	2022	1312	12	2022	1001.4537