

Année 2023-2024

SOUTENANCE TER 2 - M1 MASS POP

PROJET TER

« ETUDES DES EQUIPEMENTS DES MENAGES AU GHANA »

Projet réalisé par :

ZOGLAMI Hakim

Projet encadré par :

WILLER Thomas



TABLE DES MATIERES

I.INTRODUCITON	3
II.PRESENTATION DES DONNEES ET METHODOLOGIE	4
1.DHS ET CONTEXTE	4
2. OBJECTIF ET CONTRAINTE.....	4
3. BASE DE DONNEES	4
4. METHODOLOGIE.....	5
III.RESULTATS	6
1.ETUDE UNIVARIEE	6
2.ETUDE BIVARIEE	9
3. ANALYSE EN COMPOSANTE PRINCIPALE NORMEE (ACP).....	13
4. CLASSIFICATION ASCENDANTE HIERARCHIQUE (CAH).....	17
IV. CONCLUSION	23
ANNEXES.....	24

I. INTRODUCTION

Dans le cadre de la finalisation de mon Master 1, un projet m'a été proposé afin de mettre en pratique mes connaissances et compétences à travers une étude de données réelles collectées par le DHS (Demographic and Health Survey). Ce projet aurait dû être une soutenance de stage, mais je n'ai malheureusement pas réussi à en trouver un à cette période. Cependant, avec l'aide de Willer Thomas, j'ai pu réaliser un travail d'étude et de recherche (TER 2) en utilisant une base de données du Ghana que j'avais étudiée au semestre 1.

L'objectif principal de cette étude est d'analyser les données démographiques et sanitaires collectées dans les 10 régions du Ghana, en distinguant les zones urbaines et rurales, et en évaluant l'éligibilité des ménages à une enquête complémentaire auprès des hommes du foyer. Nous cherchons à identifier les similitudes entre les différentes régions du Ghana afin de les regrouper en clusters à l'aide de la classification ascendante hiérarchique (CAH).

Pour atteindre cet objectif, nous débuterons par une présentation détaillée des données afin de fournir un aperçu complet du jeu de données et de clarifier les enjeux du sujet. Ensuite, nous expliquerons la méthodologie utilisée en justifiant le choix des techniques statistiques adoptées. Notre analyse comprendra une exploration univariée, une analyse bivariée, une étude des variables extrêmes, une Analyse en Composantes Principales Normée (ACP), ainsi que la visualisation des résultats à travers le cercle des corrélations et la carte des individus. Enfin, nous procéderons à une classification ascendante hiérarchique pour identifier les structures similaires au sein des régions du Ghana.

II. PRESENTATION DES DONNEES ET METHODOLOGIE

1. DHS ET CONTEXTE

Les Enquêtes Démographiques et de Santé (EDS), mises en œuvre par le programme Measure DHS depuis 1984, sont des initiatives essentielles pour l'analyse des données relatives à la population, à la santé, au VIH/SIDA et à l'alimentation dans les pays en développement. Ces enquêtes jouent un rôle important en fournissant des données fiables et détaillées qui sont utilisées pour évaluer les besoins sociaux, sanitaires et nutritionnels, ainsi que pour orienter les politiques publiques et les interventions.

2. OBJECTIF ET CONTRAINTE

Dans le cadre de notre projet, nous visons à analyser les disparités dans la possession de biens et les moyens entre les différentes régions du Ghana. Notre attention se concentre spécifiquement sur la distribution des 10 biens essentiels au sein des ménages ghanéens, en distinguant les zones urbaines et rurales, ainsi que les ménages sélectionnés ou non pour une enquête ultérieure. Cette approche nous permet de définir 40 strates basées sur la combinaison des 10 régions, des zones géographiques et de la sélection à l'enquête.

3. BASE DE DONNEES

Notre analyse repose sur un tableau de données comprenant 40 lignes correspondant aux différentes strates et 11 colonnes. Chaque ligne représente une combinaison unique de région, de zone (urbaine/rurale) et de statut d'éligibilité à l'enquête supplémentaire. Les colonnes incluent les noms des strates (variables qualitatives) et les pourcentages de ménages possédants chacun des 10 biens étudiés (variables quantitatives).

4. METHODOLOGIE

Notre approche méthodologique commence par une exploration des données afin de comprendre la distribution des biens dans les ménages ghanéens. À l'aide d'analyses univariées et bivariées, nous examinons les distributions et les corrélations entre les variables pour identifier les patterns significatifs. Ensuite, une analyse des extrêmes nous permet de déterminer les biens les plus répandus et les moins répandus par strate. Pour une vue d'ensemble, nous utilisons une Analyse en Composantes Principales Normée (ACP) pour visualiser les relations entre les variables. Enfin, à l'aide de la Classification Ascendante Hiérarchique (CAH), nous regroupons les strates similaires afin de définir des clusters régionaux représentatifs de différentes classes de richesse, telles que riche, classe moyenne et pauvre. Cette approche nous permettra de mieux comprendre les disparités socio-économiques et géographiques au Ghana, et de guider les futures interventions et politiques publiques.

III.RESULTATS

Pour effectuer nos analyses, j'ai principalement utilisé SAS, un outil pour la manipulation et l'analyse de données. SAS nous a permis de réaliser les différentes étapes d'analyse, en produisant des résultats détaillés et précis. Tout au long de notre études et de nos analyses, nous avons travaillé exclusivement sur cette table que nous avons importé via Ametice (table Ghhr72fld coupé a la 6^{ème} observation volontairement) :

FIGURE 1 : TABLEAU DES POURCENTAGES DE POSSESSION DES BIENS ESSENTIELS PAR REGION ET CATEGORIE DE MENAGE AU GHANA

Obs.	SNAME2014	electricity	radio	television	refrigerator	mobilephone	computer	internet	bed	table	cupboard
1	Western_UN	0.96071	0.71071	0.81786	0.37500	0.89286	0.20714	0.93929	0.86429	0.41786	0.22857
2	Western_US	0.96667	0.71000	0.83333	0.42333	0.92667	0.24000	0.92667	0.85333	0.42667	0.16333
3	Western_RN	0.70308	0.68347	0.50980	0.14286	0.82353	0.07563	0.87675	0.85154	0.22969	0.09524
4	Western_RS	0.72877	0.66575	0.55342	0.20274	0.80548	0.06849	0.80000	0.84384	0.20274	0.06027
5	Central_UN	0.85809	0.68647	0.72277	0.42904	0.88119	0.17822	0.92739	0.88779	0.38614	0.15512
6	Central_US	0.86149	0.68243	0.68581	0.42905	0.85811	0.17905	0.89189	0.85811	0.35811	0.10811

1.ETUDE UNIVARIEE

Nous allons dans un premier temps utiliser sur SAS les commandes **PROC MEANS** et **PROC MEANS MEDIAN** pour collecter des informations sur nos variables, voici les sorties obtenues :


FIGURE 2 : TABLE SORTIE PROC MEANS ET PROC MEANS MEDIAN

La procédure MEANS						La procédure MEANS	
Variable	N	Moyenne	Ec-type	Minimum	Maximum	Variable	Médiane
electricity	40	0.7144051	0.2254160	0.1314103	0.9666667	electricity	0.7926360
radio	40	0.6565395	0.0698106	0.5130719	0.8248848	radio	0.6651552
television	40	0.5415545	0.2250660	0.1274510	0.8639456	television	0.5952441
refrigerator	40	0.2767951	0.1798578	0.0224359	0.6273830	refrigerator	0.2775529
mobilephone	40	0.8239381	0.1018624	0.5496894	0.9625850	mobilephone	0.8621751
computer	40	0.1179553	0.0810842	0.0064103	0.2932331	computer	0.0995419
internet	40	0.7751783	0.1622105	0.3621795	0.9392857	internet	0.8333774
bed	40	0.7806128	0.1374437	0.3850932	0.9207921	bed	0.8446706
table	40	0.2815413	0.1442158	0.0228013	0.5589623	table	0.2836442
cupboard	40	0.1187985	0.0818260	0.0087977	0.2536585	cupboard	0.1128776

L'analyse des possessions moyennes révèle que les biens les plus courants dans les ménages sont les téléphones portables, les lits et l'accès à Internet, tandis que les biens les plus rares sont

les armoires et les ordinateurs. Ces résultats nous permettent de classer les biens comme par exemple les plus indispensables tels que l'électricité et le lit, alors que d'autres, comme l'armoire, sont moins prioritaires. Cela sonne vrai, car il est difficile de se passer d'un lit pour dormir ou de vivre sans lumière le soir, alors qu'il est possible de se passer d'une armoire pour ranger ses affaires. De plus, un téléphone portable, étant multifonctionnel, moins coûteux et moins encombrant, peut remplacer certaines fonctionnalités d'un ordinateur, ce qui explique sa possession plus élevée par rapport aux ordinateurs. Pour mieux visualiser ces biens, nous utiliserons un diagramme en boîte (boxplot).

FIGURE 3 : BOXPLOT




Le boxplot illustre la variabilité (l'écart-type dans notre tableau) des possessions. Les biens représentés par des boxplots presque de forme carrée présentent une faible variabilité, ce qui signifie que leurs moyennes sont proches

de leurs médianes et donc significatives. En revanche, les biens tels que l'électricité, la télévision et le réfrigérateur montrent une variabilité légèrement plus élevée (environ 20 %) avec une forme rectangulaire, ce qui indique une grande disparité entre les strates, notamment pour l'électricité. On peut supposer que les régions du Nord et les zones rurales, éloignées des côtes et du commerce maritime, disposent de moins d'électricité, ce qui explique certaines valeurs extrêmes.

Pour mieux interpréter cette inégalité, nous allons maintenant nous focaliser sur la variable « electricity » et « radio » à l'aide d'un histogramme.

FIGURE 4 : HISTOGRAMME DE LA POSSESSION DE RADIO ET D'ELECTRICITE PAR STRATE



Le premier histogramme sur la variable « Radio » présente une moyenne de 0.66 et une médiane équivalente à 0.66. Les valeurs varient entre 0.51 et 0.82, avec un écart-type notablement bas de 0.07. Ces statistiques révèlent une stabilité dans la tendance centrale, indiquant peu de variation dans les valeurs observées. De plus, l'écart-type faible suggère une concentration significative des données autour de la moyenne.

Le second histogramme sur la variable « Electricity » confirme la répartition observée dans le boxplot : la majorité des données se situe entre 0,6 et 0,8. Il montre également qu'une petite partie des strates possède très peu d'électricité. Comme l'indique le premier tableau, une strate ne dispose que de 13 % d'électricité, ce qui est extrêmement bas. Cette faible valeur étire en partie notre boxplot. Il est probable que cette région soit dans une situation de grande précarité.

En résumé , nous constatons que la possession de certains biens est très hétérogène, comme l'électricité, la télévision et Internet, qui montrent des pourcentages variables entre les ménages. En revanche, d'autres équipements comme l'armoire sont possédés de manière uniforme à un faible niveau, tout comme les ordinateurs. Il est clair que des disparités significatives existent, principalement dues aux différences d'accès à l'électricité entre les strates.

La prochaine étape est d'examiner les liens entre ces biens. Par exemple, l'absence d'électricité pourrait entraîner l'absence d'ordinateur.


2. ETUDE BIVARIEE

Pour calculer la matrice de corrélation j'ai utilisé la commande **PROC CORR** (détails spécifiques de la commande sont disponibles en annexe) pour pouvoir analyser les corrélations entre les variables. Voici le résultat suivant :


FIGURE 5 : MATRICE DE CORRELATION

Coefficients de corrélation de Pearson, N = 40 Proba > r sous H0: Rho=0										
	electricity	radio	television	refrigerator	mobilephone	computer	internet	bed	table	cupboard
electricity	1.00000	0.52440 0.0005	0.95265 <.0001	0.85873 <.0001	0.81426 <.0001	0.81339 <.0001	0.80339 <.0001	0.59351 <.0001	0.85949 <.0001	0.76692 <.0001
radio	0.52440 0.0005	1.00000	0.59549 <.0001	0.65576 <.0001	0.51560 0.0007	0.46188 0.0027	0.66751 <.0001	0.55693 0.0002	0.65209 <.0001	0.40157 0.0102
television	0.95265 <.0001	0.59549 <.0001	1.00000	0.94294 <.0001	0.91393 <.0001	0.88199 <.0001	0.73865 <.0001	0.55878 0.0002	0.91855 <.0001	0.85228 <.0001
refrigerator	0.85873 <.0001	0.65576 <.0001	0.94294 <.0001	1.00000	0.85797 <.0001	0.88139 <.0001	0.63307 <.0001	0.46928 0.0023	0.92916 <.0001	0.83956 <.0001
mobilephone	0.81426 <.0001	0.51560 0.0007	0.91393 <.0001	0.85797 <.0001	1.00000	0.80914 <.0001	0.60429 <.0001	0.51197 0.0007	0.84606 <.0001	0.86098 <.0001
computer	0.81339 <.0001	0.46188 0.0027	0.88199 <.0001	0.88139 <.0001	0.80914 <.0001	1.00000	0.57124 0.0001	0.40223 0.0101	0.84219 <.0001	0.79312 <.0001
internet	0.80339 <.0001	0.66751 <.0001	0.73865 <.0001	0.63307 <.0001	0.60429 <.0001	0.57124 0.0001	1.00000	0.85110 <.0001	0.74743 <.0001	0.43935 0.0046
bed	0.59351 <.0001	0.55693 0.0002	0.55878 0.0002	0.46928 0.0023	0.51197 0.0007	0.40223 0.0101	0.85110 <.0001	1.00000	0.56868 0.0001	0.22198 0.1686
table	0.85949 <.0001	0.65209 <.0001	0.91855 <.0001	0.92916 <.0001	0.84606 <.0001	0.84219 <.0001	0.74743 <.0001	0.56868 0.0001	1.00000	0.78076 <.0001
cupboard	0.76692 <.0001	0.40157 0.0102	0.85228 <.0001	0.83956 <.0001	0.86098 <.0001	0.79312 <.0001	0.43935 0.0046	0.22198 0.1686	0.78076 <.0001	1.00000

La matrice de corrélation évalue la relation linéaire entre deux variables, avec des coefficients allant jusqu'à 1. Par exemple, une dépendance totale montre une corrélation parfaite d'une variable avec elle-même, représentée par un coefficient de 1. Dans notre étude, la matrice montre des liens linéaires significatifs entre la plupart des variables, sauf pour l'armoire et le lit, probablement à cause de données limitées pour les armoires. Ces résultats suggèrent l'existence d'une variable sous-jacente, le 'taux d'équipement,' qui influence plusieurs corrélations observées. Cela signifie que la possession d'un équipement par un ménage ghanéen est souvent liée à la possession d'autres équipements. Par exemple, la présence d'une télévision est souvent associée à l'accès à l'électricité. Les ménages possédant plusieurs biens sont les mêmes, révélant des disparités entre les strates socio-économiques.


FIGURES 6 : MATRICE DU NUAGES DE POINTS

Grace à la **PROC CORR** exécuté précédemment, nous avons eu accès à la figures 6 qui nous montre que la corrélation minimale est entre la variable « bed » et « cupboard » et que la corrélation maximale est entre la varibale « electricity » et « television ».

FIGURE 6 BIS.1 : CORRELATION MINIMALE

La corrélation entre la possession d'armoires et de lits est positive. Les strates qui possèdent plus d'armoires ont également tendance à posséder plus de lits, et vice versa. En revanche, les strates avec très peu d'armoires ont également peu de lits, et réciproquement. Cette observation s'explique par le fait que le lit est considéré comme un bien essentiel. Si

une strate possède principalement des lits, cela suggère qu'elle a les moyens d'acquérir des armoires. En revanche, une strate qui ne peut se permettre des lits ne pourra probablement pas non plus investir dans des armoires. Il est important de noter que même si une strate a le maximum d'armoires, cela ne garantit pas nécessairement le maximum de lits ; cela peut être dû au hasard. Malgré une corrélation minimale, elle reste interprétable, influencée par des données limitées, des valeurs extrêmes et d'autres corrélations plus fortes, notamment celles nécessitant l'accès à l'électricité (comme le téléphone, la télévision, le réfrigérateur, et indirectement, Internet). Ainsi, il existe forcément un lien entre la possession d'armoires et de lits, bien que cette corrélation puisse être influencée par d'autres facteurs.

FIGURE 6 BIS.2 : CORRELATION MAXIMAL

La corrélation significative observée précédemment est claire dans ce cas-ci : il existe une relation quasi linéaire entre les variables "électricité" et "télévision". Cela indique qu'une personne ayant accès à l'électricité possède presque toujours une télévision, et vice versa. Il est remarquable de noter que deux strates supposées similaires en région et en zone, et donc potentiellement similaires en termes d'éligibilité, présentent

des valeurs extrêmement basses pour ces deux variables, suggérant un accès très limité à l'électricité et à la télévision. Ce constat souligne une fois de plus que la répartition des biens n'est pas équitable.

Un aspect notable est que la possession de l'électricité est presque synonyme de possession d'une télévision, ce qui est logique puisque la télévision nécessite une source d'électricité pour fonctionner. Cela révèle un intérêt commun parmi les Ghanéens pour regarder la télévision. De plus, cela met en lumière l'importance de la télévision au Ghana et explique en partie le faible taux de possession d'ordinateurs : beaucoup trouvent information et divertissement à travers la télévision.


En conclusion, l'analyse bivariée révèle des disparités significatives au Ghana, où la possession d'un bien est souvent associée à la possession d'autres biens. Notamment, les strates ayant un accès étendu à l'électricité possèdent également un grand nombre d'autres biens, accentuant ainsi les inégalités observées. Cette analyse a permis de répondre à plusieurs de nos questions. Il reste maintenant à explorer la représentation des données selon les strates et à visualiser les variables analysées.

3. ANALYSE EN COMPOSANTE PRINCIPALE NORMEE (ACP)

Ayant complété les analyses univariée et bivariée, nous allons maintenant aborder l'Analyse en Composantes Principales (ACP). L'ACP est une technique statistique qui permet de réduire la complexité des données tout en préservant la majeure partie de leur variance. Notre but est de normaliser les données pour mettre en évidence les composantes principales qui expliquent les variations observées. Cela nous permettra de mieux saisir les relations complexes entre les différentes variables et strates que nous avons étudiées.

Pour ce faire, nous allons télécharger sur Ametice le fichier `acp.sas` pour pouvoir utiliser la macro %acp (ACP normée). Elle nous donne dans un premier temps le tableau des valeurs propres ci-dessous :

FIGURE 7 : TABLE & GRAPHIQUE VALEUR PROPRE



D'après le critère de Kaiser, nous retenons les valeurs propres λ qui sont supérieures à l'inertie moyenne, laquelle est égale à 1 dans le cas de l'ACP normalisée. Ainsi, nous conserverons les λ tels que $\lambda \geq 1$. En conséquence, seules les valeurs propres supérieures à 1 seront gardées. Nous gardons donc les valeurs propre numéro 1 (7.46) et 2 (1.26). On va donc retenir 2 axes dans l'analyse en composante principale normée. De plus, si on regarde le graphique en appliquant le théorème du coude, on prend bien 2 composantes.

Passons maintenant à l'étape suivante : le calcul des qualités de représentation des variables initiales. Cela va nous permet d'évaluer l'importance de chaque variable dans la construction des composantes principales, aidant ainsi à identifier quelles variables influencent le plus les différentes dimensions de notre analyse.

FIGURE 8 : COORDONNEES FACTORIELLES

NAME	v1	v2
electricity	0.94	-0.01
radio	0.68	0.39
television	0.98	-0.11
refrigerator	0.95	-0.17
mobilephone	0.91	-0.20
computer	0.88	-0.27
internet	0.81	0.52
bed	0.64	0.68
table	0.95	-0.03
cupboard	0.83	-0.47

Selon le cours, on mesure la qualité de la projection d'une variable j sur un axe G_α par $\text{qualite}_{\text{axe}} = (\cos)^2(\theta_{j\alpha}) = a_{j\alpha}^2$

Où $a_{j\alpha}$ est la coordonnée de la variable j sur l'axe α . Ici, on fera les calculs pour $\alpha \in \{1, 2\}$ La qualité sur le premier plan factoriel est quant à elle donnée par

$$\text{qualite}_{\text{premierplan}} = a_{j,1}^2 + a_{j,2}^2$$


On va maintenant calculer les carrées des V_x avec la méthode énoncée précédemment, ce qui nous donne :

Nom	v1	v2	Qualité sur l'axe 1	Qualité sur l'axe 2	Qualité sur le plan factoriel
electricity	0.94	-0.01	88.36	0.01	88.37
radio	0.68	0.39	46.24	15.21	61.45
television	0.98	-0.11	96.04	1.21	97.25
refrigerator	0.95	-0.17	90.25	2.89	93.14
mobilephone	0.91	-0.2	82.81	4	86.81
computer	0.88	-0.27	77.44	7.29	84.73
bed	0.64	0.68	40.96	46.24	87.2
table	0.95	-0.03	90.25	0.09	90.34
cupboard	0.83	-0.47	68.89	22.09	90.98
internet	0.81	0.52	65.61	27.04	92.65

FIGURE 9 : QUALITE DES PLANS FACTORIEL

Les variables sont globalement bien représentées sur le premier plan factoriel, avec une qualité de projection supérieure à 84 % pour toutes sauf la variable "radio," qui n'atteint que 61 %. Étant donné que cette valeur est proche de la moyenne, la variable "radio" ne sera pas notre principal focus d'interprétation ici.

Nous passons maintenant à l'analyse du cercle de corrélation pour explorer les relations entre les variables. À cet effet, nous avons utilisé RStudio, considéré comme l'outil le plus pratique pour cette tâche. Voici notre sorti :

FIGURE 10 : CERCLE DE CORRELATION

Observation du premier axe : Toutes les corrélations sont positives et fortes, sans valeurs négatives. Les flèches indiquent une bonne qualité de représentation avec des longueurs significatives.

Analyse du premier axe : Il met en évidence que la possession d'un équipement est généralement associée à la possession d'autres équipements.

Observation du deuxième axe : On distingue d'un côté les variables comme table, radio et lit qui ne nécessite pas d'électricité, et de l'autre côté, les équipements électriques. L'armoire, avec une corrélation quasiment nulle sur cet axe, est difficile à interpréter.

Analyse du deuxième axe : Il montre que la possession d'appareils électriques est inversement corrélée à celle des équipements non-électriques : ceux qui ont des équipements électriques privilégient souvent l'achat d'autres équipements électriques.

Passant maintenant à la représentation des individus sur le premier plan factoriel, nous explorons la répartition géographique et les caractéristiques socio-économiques au sein de notre échantillon.

FIGURE 10 : CARTE DES INDIVIDUS

L'axe 1 révèle clairement les disparités d'équipement entre les régions rurales et urbaines, montrant que les régions rurales, notamment R., sont moins équipées, représentées à gauche sur le graphique. Une observation intéressante est la constante translation de 5 unités entre les valeurs R et U pour chaque couleur, soulignant une différence d'équipement entre les zones rurales et urbaines. Aux extrémités du graphique, les régions Northern Upper West et Upper East (rurales), situées au nord, présentent un retard significatif en termes d'équipement, tandis qu'à droite, Accra, la capitale, se distingue. Cela indique que les régions rurales du Nord accusent un retard de développement important, tandis que les zones urbaines ont un retard plus léger. Les zones les plus favorisées comprennent la région de la capitale et les régions du Sud, ce qui est cohérent étant donné leur attractivité pour la population étrangère due au tourisme, aux études et au commerce maritime.

Quant à l'axe 2, il oppose les strates moyennes aux strates extrêmes et semble suivre une tendance quadratique par rapport au premier axe. Les strates situées en haut correspondent à des niveaux moyens d'équipement, principalement dans les parties rurales des régions riches. On remarque également une similitude marquée entre les valeurs S et NS d'une même zone dans une région, indiquant que l'éligibilité n'a pas d'incidence significative sur le taux d'équipement. En conclusion, la géographie (Nord ou Sud) et le milieu urbain sont des critères distinctifs dans le premier plan factoriel, tandis que l'éligibilité a peu d'impact, ce qui est attendu compte tenu de la sélection arbitraire de près de la moitié des ménages.

4. CLASSIFICATION ASCENDANTE HIERARCHIQUE (CAH)

En résumé des analyses antérieures, nous constatons une répartition différenciée des variables et des régions sur le premier plan factoriel. Nous entamons maintenant l'étape suivante avec l'analyse par Classification Ascendante Hiérarchique (CAH) afin d'approfondir l'étude des regroupements potentiels dans notre jeu de données.

La Classification Ascendante Hiérarchique (CAH) est une méthode statistique qui regroupe des données similaires en clusters. Son but est de révéler des regroupements naturels parmi les observations en se basant sur leur proximité ou leur similitude. Cette approche commence par considérer chaque observation comme un cluster individuel et fusionne progressivement les clusters les plus similaires jusqu'à ce que toutes les observations soient regroupées. La CAH est largement utilisée pour analyser et visualiser la structure des données dans divers domaines comme la biologie, la sociologie et le marketing, permettant ainsi de découvrir des relations et des tendances cachées.

Nous allons utiliser une approche de classification non supervisée pour identifier les groupes naturels dans nos données. Pour cela, nous utiliserons SAS avec la commande PROC CLUSTER en utilisant la méthode de Ward. Cette méthode vise à minimiser la variance intra-cluster en fusionnant les clusters de manière à maintenir la compacité des groupes formés. Nous utiliserons les options « pseudo rsquare simple » pour évaluer la qualité du clustering et « standard » pour normaliser nos données en les centrant et les réduisant.

Voici nos sorti SAS :

FIGURE 11 : COURBES PSEUDO F ET PSEUDO CARRE T



Ces figures montrent les valeurs de ces critères en fonction du nombre de clusters. Pour choisir le bon nombre de clusters, il est crucial de repérer théorème du « coude », indiquant où les courbes commencent à se stabiliser. Cependant, la sortie actuelle ne permet pas une localisation précise de ce point critique.

Nous allons donc zoomer sur le graphique et utiliser une commande spécifique dans SAS pour mieux identifier ce point décisif.






FIGURE 12 : R-CARRE SEMI-PARTIEL & PSEUDO F ET CARRE T

Le nombre optimal de clusters pour notre étude semble être 3. Nous allons maintenant examiner le dendrogramme pour déterminer dans quel groupe (1, 2 ou 3) chaque région est classée selon les critères US, UNS, RS et RNS.

FIGURE 13 : D'ENDROGRAMME

La ligne verte tracé sur la figure ci-dessus nous montre la coupure pour matérialiser les 3 groupes de notre base de données.

Nous obtenons:

Groupe 1: Greater Accra _UNS/ Greater Accra_ US/ Central_UNUS/ Eastern_US /Ashanti_UNUS
/Ashanti_US Central _US/ Brong Ahafo_UNUS/ Eastern UNS/ Northern_UNUS/ Northern US/
Western UNS/ Western_US/ Volta_US/ Brong Ahafo US/ Upper West UNS/ Upper West _US/
Greater Accra RS/ Upper East US/ Upper East UNS /Greater Accra RNS

Groupe 2: Volta RNS/ Eastern RS/ Brong Ahafo_RNS / Brong Ahafo RS /Western_RS /Ashanti RNS
/Central RS /Western _RNS /Volta RS/ Eastern RNS/ Central_RNS /Volta UNS /Ashanti RS

Groupe 3: Northern_RNS /Northern_RS /Upper East RNS /Upper East_RS/ Upper West RNS /Upper West RS

FIGURE 14 : MOYENNE DES VARIABLES PAR CLASSE

	classes			Ensemble
	1	2	3	
	moyenne	moyenne	moyenne	
electricity	0.88	0.64	0.31	0.71
radio	0.68	0.65	0.57	0.66
television	0.72	0.43	0.16	0.54
refrigerator	0.42	0.16	0.03	0.28
mobilephone	0.90	0.77	0.66	0.82
computer	0.18	0.06	0.02	0.12
internet	0.84	0.82	0.44	0.78
bed	0.81	0.85	0.51	0.78
table	0.39	0.22	0.06	0.28
cupboard	0.19	0.05	0.03	0.12

Cette table nous permet de comprendre énormément de chose sur la création des 3 groupes. Pour la variable "Electricity" dans notre analyse par Classification Ascendante Hiérarchique (CAH), les classes révèlent des écarts significatifs : la classe 1 présente un accès élevé à l'électricité (88%), bien au-dessus de la moyenne générale (71%). Cette classe pourrait représenter les individus ayant un niveau de vie plus élevé ou un meilleur pouvoir d'achat. En revanche, la classe 3 affiche la plus faible prévalence avec seulement 31%, suggérant des conditions socio-économiques moins favorables pour cette catégorie.

Pour la variable "Cupboard", toutes les classes montrent des moyennes relativement basses, avec la classe 1 légèrement au-dessus de la moyenne globale (19% contre 12%). Cela indique que la possession d'armoires est généralement faible dans notre ensemble de données, sans grande variation entre les groupes identifiés.

Ces observations soulignent des disparités potentielles en termes de pouvoir d'achat et de mode de vie entre les groupes identifiés par la CAH. Il est plausible que les trois groupes reflètent différentes strates socio-économiques, le groupe 1 étant potentiellement associé à des

conditions de vie plus aisées, tandis que le groupe 3 pourrait représenter des individus avec des conditions plus précaires.

FIGURE 15 : VALEUR TEST

	valeur test		
	Classes		
	1	2	3
electricity	4.70	-1.47	-4.65
radio	2.57	-0.40	-3.07
television	5.18	-2.15	-4.43
refrigerator	5.20	-2.79	-3.62
mobilephone	5.04	-2.23	-4.11
computer	5.17	-3.21	-3.02
internet	2.81	1.11	-5.39
bed	1.62	2.26	-5.23
table	4.71	-1.91	-4.08
cupboard	5.47	-3.65	-2.86

Après avoir examiné les valeurs de test t pour les variables "Electricity" et "Cupboard", nous constatons que ces résultats fournissent des indications précieuses sur les niveaux de possession d'équipements entre les groupes formés par la classification hiérarchique ascendante. La règle de décision standard, où une valeur de test t supérieure à 2 indique une possession significativement supérieure à la moyenne attendue et une valeur inférieure à -2 indique une possession significativement inférieure, est cruciale pour interpréter ces résultats.

Pour la variable "Electricity", le Groupe 1 présente un test t de 4,70, suggérant une possession d'équipement électrique bien au-dessus de la moyenne attendue. En revanche, le Groupe 3 affiche un test t de -4,65, indiquant une possession nettement inférieure à la moyenne pour cette même variable. Quant à la variable "Cupboard", le Groupe 1 montre un test t de 5,47, démontrant une possession substantiellement supérieure d'armoires, tandis que le Groupe 2 présente un test t de -3,65, révélant une possession notablement inférieure d'armoires. Ces résultats mettent en lumière les disparités significatives entre les groupes identifiés par la CAH, en fonction de leurs niveaux de possession spécifiques. En résumé, lorsque nous examinons l'ensemble des données, il est clair que le Groupe 1 est caractérisé par une richesse élevée en équipements, le Groupe 2 par un niveau moyen et le Groupe 3 par des possessions plus précaires.

IV. CONCLUSION

Nous concluons cette étude sur les relations entre la possession de biens et les caractéristiques des ménages dans différentes régions du Ghana.

L'analyse univariée a révélé que certains biens, comme l'électricité et le lit, sont essentiels, tandis que d'autres, comme l'armoire, le sont moins. Les boxplots ont mis en évidence des variations significatives entre les régions, soulignant des disparités importantes.

L'étude bivariée a montré une forte corrélation entre la possession d'électricité et de télévision, confirmant l'importance de l'électricité dans l'équipement des ménages ghanéens et les disparités existantes.

L'Analyse en Composantes Principales Normée (ACP) a permis de représenter efficacement les données et de visualiser les disparités entre le Nord et le Sud du Ghana et entre les zones rurales et urbaines.

Enfin, nous avons réalisé une Classification Ascendante Hiérarchique (CAH) en utilisant la méthode de Ward. Trois clusters optimaux ont été identifiés, reflétant des niveaux de vie différents : le groupe 1 étant le plus aisé, le groupe 2 intermédiaire, et le groupe 3 le plus précaire. L'analyse des valeurs de test t a confirmé ces différences.

En conclusion, notre étude met en lumière les disparités géographiques, l'importance de l'électricité et les différences de niveaux de vie au Ghana. Ces résultats devraient orienter les actions pour améliorer l'accès aux équipements et réduire les inégalités.

ANNEXES

1. CODE SAS

```

data ghana ; set " /home/u63725262/ghhr72fl_d.sas7bdat" ; run ;
/* études univariées */
/* On affiche les moyennes, écarts-types, valeurs minimales et
maximales */
proc print data = ghana ; run ;
PROC MEANS DATA = work.ghana;
RUN ;
/* Calcul de l'écart-type */
PROC MEANS MEDIAN DATA = work.ghana ;
RUN ;
/* Création d'un ensemble de données au format long pour faciliter
le tracé */
data ghana_long;
  set ghana;
  category = "electricity"; value = electricity; output;
  category = "cupboard"; value = cupboard; output;
  category = "computer"; value = computer; output;
  category = "mobilephone"; value = mobilephone; output;
  category = "radio"; value = radio; output;
  category = "television"; value = television; output;
  category = "refrigerator"; value = refrigerator; output;
  category = "internet"; value = internet; output;
  category = "bed"; value = bed; output;
  category = "table"; value = table; output;
  keep category value;
run;
/* Tracé des boxplots avec ajustements */
proc sgplot data=ghana_long;
  vbox value / category=category
              group=category
              fillattrs=(color=white)
              outliersattrs=(symbol=CircleFilled)
              ;
  xaxis label="Catégorie" display=(nolabel);
  xaxis fitpolicy=rotate; /*
  yaxis label="Valeur";
  title "Boxplots des différentes catégories";
run;

```



```

/*Histogramme de l'électricité*/
PROC SGPLOT DATA=work.ghana;
HISTOGRAM electricity;
RUN;
PROC SGPLOT DATA=work.ghana;
HISTOGRAM radio;
RUN;

/* études bivariées*/
/*Matrice de corrélation*/
PROC CORR DATA=work.ghana plots=matrix(histogram);
RUN;
/* Scatter plot pour les deux variables les plus corrélées
positivement */
proc sgplot data=work.ghana;
    scatter x=television y=electricity /
markerattrs=(symbol=CircleFilled);
    xaxis label="Télévision";
    yaxis label="Électricité";
    title "Scatter Plot de l'Électricité vs Télévision";
run;
/* Scatter plot pour les deux variables les moins corrélées */
proc sgplot data=work.ghana;
    scatter x=cupboard y=bed / markerattrs=(symbol=CircleFilled);
    xaxis label="Placard";
    yaxis label="Lit";
    title "Scatter Plot du Lit vs Placard";
run;

/*ACP*/
/* Inclure le fichier contenant la macro */
%include '/home/u63725262/acp.sas';
/* Appel de la macro pour l'ACP */
%acp(work.ghana,SNAME2014,electricity--cupboard,q=4);
/* ACP Normée Centrée Réduite avec PROC PRINCOMP */
proc princomp data=work.ghana out=princomp_out plots=all;
    var electricity--cupboard;
run;

/*CAH */
/* classification */
proc cluster data=ghana method=ward outtree=tree pseudo rsquare
simple standard;
id sname2014;
var electricity--cupboard;
run;
/*****Graphiques *****/
proc sort data=tree;

```

```

    by _ncl_;
run;

    /***sprsq ***/
data sprsq;
    set tree;
    by _ncl_;
if first._ncl_;
keep _ncl_ _sprsq_;
run;
proc gplot data=sprsq;
where _ncl_ <10 ;
plot _sprsq*_ncl_;
symbol i=join;
run;
quit;
    /*** pseudo f et pseudo t ***/
data FT2;
    set tree ;
    by _ncl_;
    if first._ncl_;
    if _psf=. and _pst2=. then delete;
    keep _ncl_ _psf_ _pst2_;
    legend1 across=2 cborder=red
    position = (top right inside ) mode = protect
    label=none
    value= (h= 0.5 tick=1 "F" tick=2 "T2");
    axis1 label = none;
    symbol1 c=green i=join l=1;
    symbol2 c=red i=join l=2 ;
run;

proc gplot data= FT2 ;
where _ncl_ < 15;
plot (_psf_ _pst2_)*_ncl_/overlay legend=legend1 vaxis=axis1;
run;
quit;
/*créer la table avec affectation des classes pour une partition de
taille 3*/
proc tree data=tree out=out nclusters=3;
copy electricity--cupboard;
id sname2014 ;
run;

proc print data=out;
run;

proc sort data=out;
    by cluster;

```

```

run;

%LET selvar=electricity
radio
television
refrigerator
mobilephone
computer
internet
bed
table
cupboard;

proc print data=out;
var sname2014 &selvar;
by cluster;
run;
/* moyennes des variables par classes */
proc tabulate data=out noseps format=8.2;
class cluster;
var &selvar;
table(&selvar), (cluster all="Ensemble")*mean /rts=15 condense;
label cluster="classes";
keylabel mean="moyenne";
run;
/* valeurs tests*/
%macro valeurtest(vble) ;
title "";
PROC SQL;
CREATE TABLE meanbyclus AS
SELECT DISTINCT mean(&vble) as byclus_m&vble, cluster, 1 as indic,
count(*) as nl
FROM out
GROUP BY cluster;

CREATE TABLE meantot AS
SELECT DISTINCT mean(&vble) as m&vble, var(&vble) as var&vble, 1 as
indic, count(*) as n
FROM out;
create table pourvaleurtest as
select data1.cluster, data1.byclus_m&vble, data2.m&vble,
data2.var&vble, data1.n1, data2.n
from meanbyclus as data1 FULL JOIN meantot as data2
on data1.indic=data2.indic;
create table &vble as
select cluster as cluster,(((byclus_m&vble-m&vble)/sqrt(((n-
n1)/n1)*(var&vble/(n-1)))) as &vble

```

```

from pourvaleurtest
order by cluster
;
QUIT;
%mend valeurtest;
%valeurtest(%scan(&selvar,1,' '));
%valeurtest(%scan(&selvar,2,' '));
%valeurtest(%scan(&selvar,3,' '));
%valeurtest(%scan(&selvar,4,' '));
%valeurtest(%scan(&selvar,5,' '));
%valeurtest(%scan(&selvar,6,' '));
%valeurtest(%scan(&selvar,7,' '));
%valeurtest(%scan(&selvar,8,' '));
%valeurtest(%scan(&selvar,9,' '));
%valeurtest(%scan(&selvar,10,' '));

data vt;
merge &selvar;
by cluster;
run;

Title "Valeurs tests";
proc tabulate data=vt nosp format =8.2;
class cluster ;
var &selvar;
table(&selvar),
mean="valeur test"*(cluster)
/rt=15 condense;
label cluster='Classes';
/*keylabel mean='moyenne';*/
run;

```

2. BIBLIOGRAPHIE

Contributeurs de Wikipédia. "Enquêtes démographiques et de santé." Wikipédia, l'encyclopédie libre. https://fr.wikipedia.org/wiki/Enquêtes_démographiques_et_de_santé#:~:text=Les%20enquêtes%20démographiques%20et%20de,dans%20les%20pays%20en%20développement. Consulté le 27/06/2024.

Chesneau, Christophe. "Éléments de la classification." Université de Caen. <http://www.math.unicaen.fr/~chesneau/>. Consulté le 10/06/2024.

YouTube. "Apprentissage automatique pour les nuls." YouTube, 2024, https://youtu.be/SE_4dLh5vXY?si=MNi5d_QyhbdU4eKJ. Consulté le 28 juin 2024.